

レポート作成技術

電気電子システム工学科 5 年 貝沼遼太郎

2021 年 05 月 11 日


1 目的

2 課題

2.1 ニューラルネットワークの仕組み，モデルの構築から学習，推論の流れについてまとめよ

2.1.1 ニューラルネットワークモデル (NeuralNetwork)

まずは，図のような単純な全結合層を3つほど使った多層ニューラルネットワークモデルを見てみる．いちばん上の行を入力層という．今回のモデルは8個の入力ユニット（ノードともいう）を持っている．上から2番目の層を中間層という．今回のモデルでは6個のユニットを持っている．最後の層を出力層という．今回のモデルでは8個の出力のユニットを持っている．中間層のことを隠れ層と呼ぶ場合もある．また，3層以上のモデルをディープニューラルネットワーク (DeepNeuralNetwork:DNN) と呼ぶ．ユニットとユニットを繋ぐ線の事を，エッジという．各エッジは重みを持つ．つまり，エッジを通るとエッジの重み分の掛け算が実行される．ユニットでは，前の層の各ノードの値がエッジの重みの値をかけたものを総和し，ユニットの値とする．ユニットの値に活性化関数を通したものがそのユニットの値となり次の層に送られる．



$$v_j = \sigma(w_{j0}u_0 + w_{j1}u_1 + w_{j2}u_2 + \cdots + w_{jn}u_n + b_j)$$

図1 多層ニューラルネットワークモデル

基本は掛けて足す（積和）の繰り返し．

行列・ベクトルを使って表記すると $v = \sigma(Wu + b)$

W は重み行列 (WeightMatrix) で，ニューロとニューロを繋ぐ線を通ると， W_{jn} の係数が掛け算される．

2.1.2 活性化関数 (ActivationFunction)

$\sigma()$ は活性化関数 (ActivationFunction) でカッコの中の値を ReLU 関数や tanh 関数やシグモイド関数として出力する． $\sigma()$ のカッコの中の値をそのまま出力するもの， $\sigma(x) = x$ を恒等関数という．

単純なDNNやCNNでよく使われるのがReLU関数

$$y = \max(0, x)$$

RNNでよく使用されるのが tanh関数（双曲線正接：ハイパーボリックタンジェント）

$$y = \tanh x$$

sigmoid関数は確率値の出力に使われる

$$y = \frac{1}{1 + e^{-x}}$$

この他マルチクラス分類によく使われるのがsoftmax関数（合計が1になる）




図2 多層ニューラルネットワークモデル

2.1.3 畳み込み（Convolution）

畳み込みは、ニューラルネットワークの入力層に入力する前の前処理として使う。




図3 多層ニューラルネットワークモデル

画像処理の中核になっているのが畳み込み層。

3 × 3 や 5 × 5 といったサイズのカーネル（画像処理でいうフィルタ）をスライドさせながら、カーネルの重みを対応する部分行列に掛けて和を取り、バイアスを加えたものを出力の1要素とする。

そのままだと出力のサイズが小さくなるがパディングを行ってサイズを変えない場合もある。

カラー画像などの場合には、カーネルは3次元になる。RGBなので赤色を表すのに数値として0～255の範囲の値をもち、同様に緑色0～255、青色0～255の3色があるので3次元となる。さらに、PNG等は透明色のαチャンネルをもっており、RGBAの4次元になっている場合もある。

カーネルの数が出力のチャンネル数になる。

2.1.4 プーリング (Pooling)

プーリングも、ニューラルネットワークの入力層に入力する前の前処理として使う。




図4 多層ニューラルネットワークモデル

特徴を抽出しサイズを縮小するのがプーリング層の役割。

プールサイズは画像処理では 2×2 がよく使われる。

2×2 のサイズで 2 個ずつスライドさせれば画像は縦横それぞれ半分のサイズになる。

出力のチャンネル数は変わらない。

画像処理では最大値を取る Max プーリングをよく使う。

2.1.5 畳み込みニューラルネットワーク (ConvolutionDeepNeuralNetwork)

CNN では、下図のように隠れ層は「畳み込み層」と「プーリング層」で構成される。

畳み込み層は、前の層で近くにあるノードにフィルタ処理して「特徴マップ」を得る。

プーリング層は、畳み込み層から出力された特徴マップを、さらに縮小して新たな特徴マップとする。

この際に着目する領域のどの値を用いるかだが、図のように最大値を得ることで、画像の多少のずれも吸収される。

したがって、この処理により画像の位置移動に対する不偏性を獲得したことになる。




図5 多層ニューラルネットワークモデル

畳み込み層は画像の局所的な特徴を抽出し、プーリング層は局所的な特徴をまとめあげる処理をしている。

つまり、これらの処理の意味するところは、入力画像の特徴を維持しながら画像を縮小処理していることになる。

今までの画像縮小処理と異なるところは、画像の特徴を維持しながら画像の持つ情報量を大幅に圧縮できるところである。これを言い換えると、画像の「抽象化」ともいう。

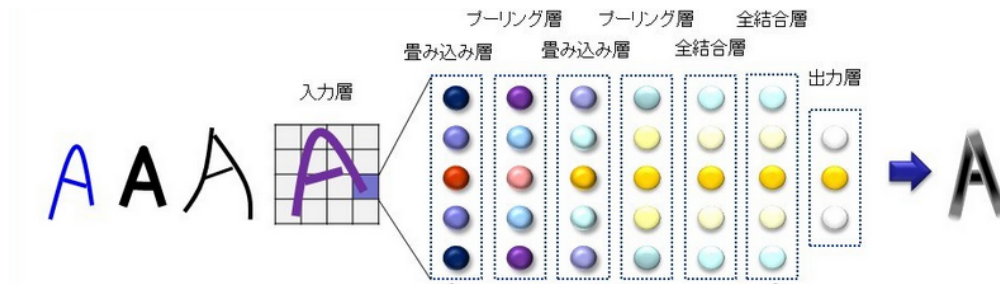


図 6 多層ニューラルネットワークモデル

- 2.2 画像分類の精度を上げるため、keras_hands-on_textbook.ipynb のコードを参考にして精度向上を行え。精度向上前と精度向上後とを比較し、改善あるいは劣化を考察せよ
- 2.3 過学習とはどのようなことを言うのか、また今回の実験で過学習が発生しているかを考察せよ
- 2.4 過学習を防止するための手法について考察せよ
- 2.5 ファインチューニングの手法について考察せよ

3 参考文献

- 「Python によるデータ解析応用編」-矢野 昌平